

BAB 6

HQC-2026 untuk Quantum Machine Learning

Panduan praktis memahami, mengaudit, dan memakai dataset intrusion detection hibrida kuantum-klasik

Hatma Suryotrisongko

Berbasis inspeksi langsung artefak Mendeley Data versi 1 • 13 Oktober 2026

Materi pendidikan • Institut Teknologi Sepuluh Nopember

Tentang bab ini

Bab ini membawa pembaca dari nol hingga mampu membuka HQC-2026, memahami arti kelompok fiturnya, mendeteksi jebakan kebocoran target, membuat baseline klasik, lalu menjalankan eksperimen quantum kernel yang kecil dan adil. Penjelasan memakai bahasa sederhana, tetapi keputusan teknisnya tetap mengikuti praktik penelitian yang dapat diaudit.

Temuan utama dari inspeksi artefak

Halaman Mendeley dan isi arsip versi 1 tidak sepenuhnya selaras. Karena itu, bab ini selalu memisahkan klaim halaman dari fakta yang dapat dihitung langsung dari tiga berkas Parquet.

Capaian pembelajaran

- Menjelaskan data aliran jaringan, label serangan, QKD, QBER, dan hubungan fitur klasik dengan fitur kuantum-terinspirasi.
- Memilih berkas Parquet yang sesuai dan membacanya tanpa menghabiskan memori.
- Mengaudit jumlah baris, kelas, nilai hilang, duplikasi, ketidakseimbangan, dan hubungan deterministik antarfitur.
- Mencegah target leakage dan membangun pemisahan train/test yang dapat dipertanggungjawabkan.
- Membandingkan SVM klasik dengan QSVC memakai data, fitur, dan split yang sama.
- Menafsirkan balanced accuracy, macro-F1, recall serangan, false-positive rate, dan confusion matrix.
- Menulis laporan yang tidak mengklaim keunggulan kuantum tanpa bukti komputasi yang kuat.

Peta perjalanan belajar

Tahap	Pertanyaan kunci	Hasil
1. Kenali	Apa isi dataset dan apa yang diwakili satu baris?	Model mental yang benar
2. Audit	Apakah ringkasan halaman sama dengan isi berkas?	Catatan mutu dan risiko
3. Siapkan	Fitur mana yang aman, skala apa yang sesuai?	Train/test siap pakai
4. Bandingkan	Bagaimana baseline klasik dan quantum kernel diuji adil?	Metrik dan confusion matrix
5. Laporkan	Apa yang dapat dan tidak dapat disimpulkan?	Kesimpulan yang jujur

Cara memakai bab

- **Jalur cepat:** baca Bagian 1–4, kemudian ikuti Praktikum Utama.
- **Jalur penelitian:** tambahkan audit leakage, ablation study, split waktu, dan pelaporan reproduktif.
- **Jalur tanpa komputer kuantum:** jalankan simulator lokal; perangkat keras nyata bersifat opsional dan tidak dibutuhkan untuk memahami alur.

1. Dataset ini menjawab masalah apa?

1.1 Intrusion detection sebagai pemeriksaan arus lalu lintas

Bayangkan jaringan komputer seperti jalan raya. Setiap aliran komunikasi adalah kendaraan: ada tujuan, lama perjalanan, jumlah paket, ukuran muatan, dan pola berhenti. Network Intrusion Detection System (NIDS) bertugas mengenali arus yang wajar serta arus yang menyerupai serangan.

Satu baris HQC-2026 merangkum sebuah aliran jaringan. Kolom seperti tot_fwd_pkts, flow_duration, dan pkt_len_mean menggambarkan perilaku aliran. Kolom label menyatakan kelas trafik yang diberikan pembuat dataset.

1.2 Mengapa ada fitur kuantum?

Dataset menambahkan deskriptor dari simulasi Quantum Key Distribution (QKD) protokol BB84. Dalam BB84, pengirim dan penerima memilih basis pengukuran. Setelah basis yang tidak cocok dibuang, mereka memperoleh sifted key. Gangguan atau penyadapan dapat menaikkan Quantum Bit Error Rate (QBER).

Istilah	Makna sederhana	Kolom yang terlihat
QBER	Proporsi bit kunci tersaring yang berbeda antara pengirim dan penerima	qber
Sifted key rate	Laju atau proporsi bit yang tersisa setelah penyaringan basis	sifted_key_rate
Fidelity	Ukuran kedekatan hasil dengan keadaan ideal	fidelity
Delta QBER	Selisih QBER terhadap acuan 0,01 pada artefak ini	qber_delta
Anomali QKD	Flag biner dari ambang QBER	is_anomalous_qkd

Penting

Fitur kuantum-terinspirasi bukan berarti data dikumpulkan dari komputer kuantum. Nilainya berasal dari simulasi QKD. Model QML kemudian dapat mengenkode angka tersebut ke sirkuit kuantum.

1.3 Tiga lapis yang jangan tertukar

Lapis	Apa yang terjadi	Contoh
Data jaringan	Aliran jaringan diringkas menjadi angka	paket/detik, durasi, flag TCP
Fitur QKD simulasi	Simulasi BB84 menghasilkan indikator kuantum-terinspirasi	QBER, fidelity
Model QML	Fitur numerik dipetakan ke keadaan kuantum untuk klasifikasi	quantum kernel atau VQC

Dataset tidak otomatis memberikan keunggulan kuantum. Keunggulan hanya mungkin jika pemetaan kuantum menangkap struktur yang sulit atau mahal bagi metode klasik, dan klaim itu harus dibuktikan lewat eksperimen yang adil.

2. Identitas dan fakta artefak HQC-2026

2.1 Identitas publikasi

Elemen	Nilai
Judul	A Hybrid Quantum-Classical Network Intrusion Detection Dataset
Nama ringkas	HQC-2026
DOI	10.17632/68rc9crgkj.1
Versi dan tanggal	Versi 1, 9 Januari 2026
Kontributor	Iftekharul Islam; Ibrahim Reza Rabbi; Tasfiqul Hasnat Emon; Arafat Sahin Afridi; Fernaz Nur
Institusi lingkungan uji	Military Institute of Science and Technology (MIST), Bangladesh, menurut halaman dataset
Lisensi	CC BY 4.0
URL	https://data.mendeley.com/datasets/68rc9crgkj/1

2.2 Klaim halaman dan fakta berkas

Aspek	Halaman Mendeley	Inspeksi ZIP versi 1
Jumlah sampel	14,69 juta	233.844 baris pada masing-masing dari 3 berkas
Keseimbangan	Kelas seimbang sempurna; label diseimbangkan SMOTE	Benign 75,99%; kelas terkecil SQL Injection 0,0325%
Dimensi	89 klasik + 7 kuantum-terinspirasi = 96	89 field pada base; 96 kolom pada v3; 104 kolom pada v4, masing-masing termasuk label
Kelas	7 kategori serangan + benign	14/15 label granular; dapat dikelompokkan menjadi keluarga
OpenQASM	Disebut tersedia	ZIP yang diperiksa hanya berisi 3 berkas Parquet

Cara membaca perbedaan

Jangan menebak penjelasan yang tidak disediakan. Laporkan dua sumber fakta secara terpisah: ringkasan halaman dan hasil inspeksi artefak. Untuk eksperimen, isi berkas yang benar-benar dipakai adalah sumber operasional.

2.3 Daftar berkas

Berkas	Ukuran	Baris	Struktur	Pilihan penggunaan

Berkas	Ukuran	Baris	Struktur	Pilihan penggunaan
final_hybrid_cybersecurity_dataset.parquet	94.019.256 B	233.844	89 field pada schema; timestamp menjadi index di pandas; label Bot belum dipecah	Audit waktu dan versi paling dasar
SUPER_ENRICHED_hybrid_dataset_v3.parquet	100.868.174 B	233.844	96 kolom; 95 calon input + label; Bot-Stealth/Aggressive	Pilihan utama praktikum
HQC20_Super_Enriched_Dataset_v4.parquet	105.674.659 B	233.844	104 kolom; 103 calon input + label; tambah delapan fitur risiko	Analisis fitur lanjutan

Ketiga berkas berisi transformasi bertingkat dari observasi yang sama. Jangan menggabungkannya secara vertikal karena itu akan menghitung observasi yang sama berulang kali.

2.4 Pemeriksaan integritas

Pemeriksaan	Hasil pada v3/v4
Nilai kosong	0
Nilai ±∞	0
Baris duplikat penuh	0
Jumlah label unik	15
Memori saat v3 dimuat penuh dengan pandas	sekitar 182,2 MiB

Checksum SHA-256 untuk reproduksibilitas dicantumkan pada Lampiran C. Jika hash berbeda, versi atau hasil unduhan Anda mungkin berbeda.

3. Memahami struktur kolom

3.1 Delapan keluarga fitur klasik

Keluarga	Contoh	Pertanyaan yang dijawab
Identitas aliran	dst_port, protocol	Tujuan layanan dan protokol apa yang dipakai?
Volume	tot_fwd_pkts, totlen_bwd_pkts	Berapa banyak paket dan byte lewat?
Ukuran paket	pkt_len_mean, fwd_pkt_len_max	Seberapa besar dan bervariasi paket?
Laju	flow_byts/s, fwd_pkts/s	Seberapa cepat trafik mengalir?
Jeda waktu	flow_iat_mean, bwd_iat_std	Bagaimana ritme antar-paket?
Flag TCP	syn_flag_cnt, ack_flag_cnt	Bagaimana keadaan sesi TCP?

Keluarga	Contoh	Pertanyaan yang dijawab
Subflow/bulk	subflow_fwd_byts, fwd_byts/b_avg	Bagaimana transfer besar terkelompok?
Aktif dan idle	active_mean, idle_max	Berapa lama aliran aktif atau diam?

3.2 Fitur pengayaan yang terlihat

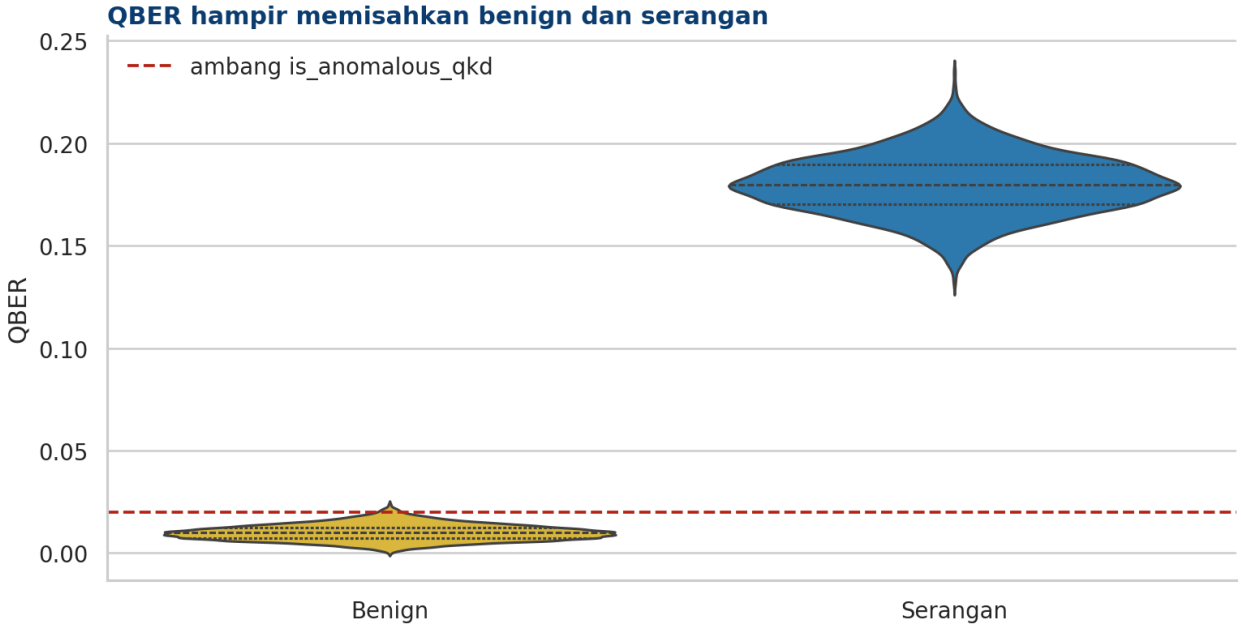
Kelompok	Kolom	Catatan
QKD dasar	qber; sifted_key_rate; fidelity; qber_delta; is_anomalous_qkd	Lima kolom terkait simulasi QKD
Flag semantik serangan	is_web_attack_specific; is_ddos_attack; is_bruteforce_attack; matches_modern_attack_type	Sangat dekat dengan label; risiko leakage
Payload	payload_entropy; special_char_count	Nilai pada artefak hanya memiliki dua nilai unik
Rolling 10 detik	qber_rolling_mean_10s; qber_rolling_std_10s; fwd_pkts_rolling_sum_10s; fwd_pkts_rolling_std_10s; flow_duration_rolling_mean_10s; flow_duration_rolling_std_10s	Ringkasan jendela waktu pada v3/v4
Risiko lanjutan v4	is_reconnaissance; is_mitm_suspicious; is_exfiltration_suspicious; data_exfil_risk; recon_risk; bruteforce_risk; ddos_risk; quantum_channel_instability	Delapan tambahan pada v4

Ketidaksesuaian angka fitur

Istilah “7 quantum-inspired features” pada halaman tidak dipetakan satu per satu ke schema. Artefak menunjukkan 5 kolom QKD dasar, 4 flag semantik, lalu fitur rolling/payload dan risiko tambahan. Buku ini memakai nama kolom aktual, bukan memaksa klasifikasi yang tidak terdokumentasi.

3.3 Relasi deterministik

Relasi pada v3	Konsekuensi
fidelity = 1 − qber	Menyimpan keduanya tidak menambah informasi baru.
qber_delta = qber − 0,01	qber_delta sepenuhnya dapat dihitung dari qber.
is_anomalous_qkd = 1 jika qber > kira-kira 0,02	Flag merangkum ambang; mudah membuat model terlalu optimistis.
Semua baris serangan memiliki is_anomalous_qkd = 1; hanya 0,924% benign yang bernilai 1	Hubungan hampir identik dengan target biner.



Gambar 6.1. Distribusi QBER dari sampel artefak v3. Pola ini harus diperlakukan sebagai risiko kebocoran atau konstruksi label, bukan bukti bahwa model belajar ancaman dunia nyata.

3.4 Apa arti satu baris?

Pada v3/v4, satu baris berisi ringkasan aliran jaringan, fitur QKD simulasi, fitur pengayaan, dan label. Nilai seperti 1339,857 pada dst_port dapat muncul sebagai pecahan karena berkas tampak telah melalui agregasi atau transformasi. Port jaringan asli biasanya bilangan bulat; ini contoh lain bahwa pengguna tidak boleh menganggap setiap nilai sebagai paket mentah.

Batas interpretasi

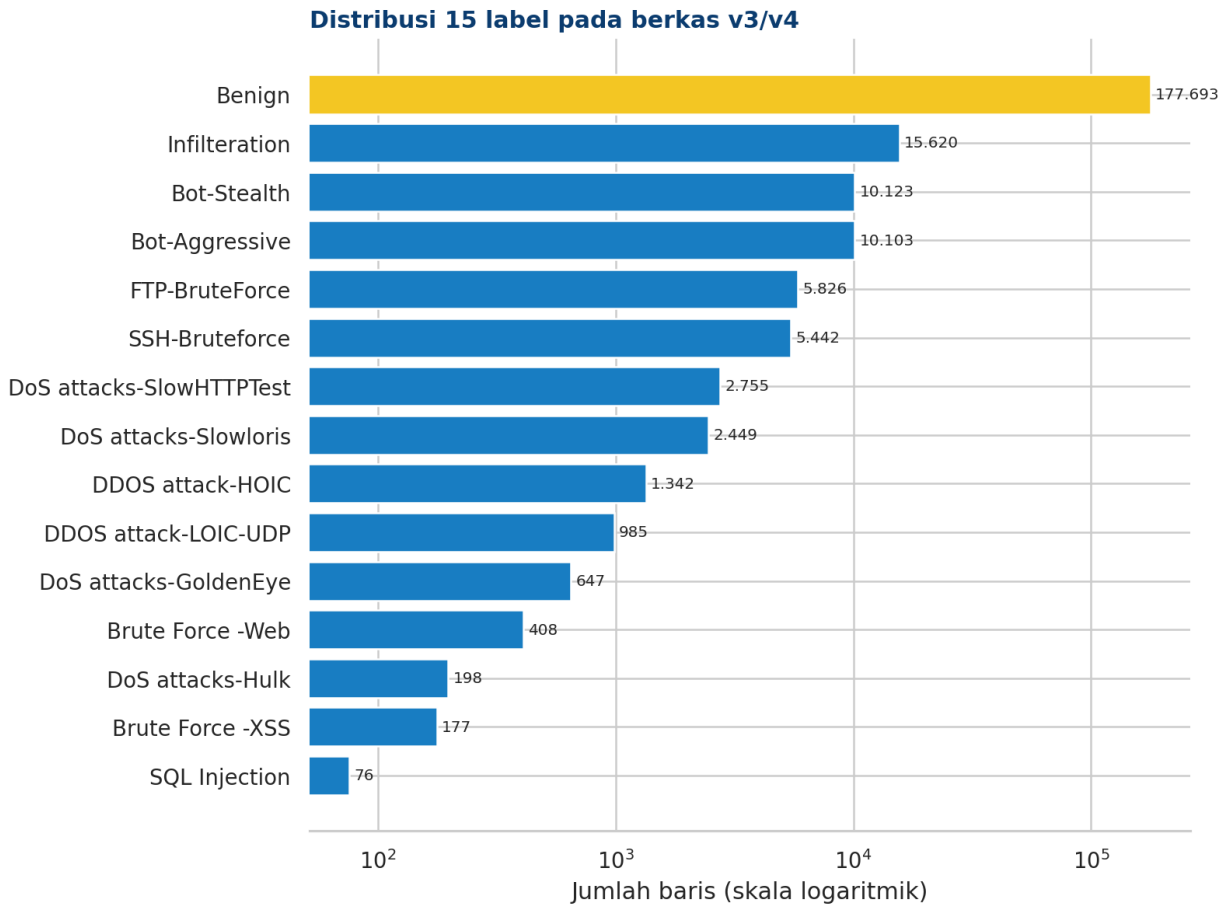
Dokumentasi terlampir tidak menyertakan data dictionary resmi atau kode pembentukan fitur. Interpretasi nama kolom klasik mengikuti konvensi umum CICFlowMeter, sedangkan satuan dan transformasi harus dipastikan kembali sebelum klaim forensik.

4. Label, keluarga serangan, dan ketidakseimbangan

4.1 Lima belas label granular

Label	Baris	Proporsi	Arti ringkas
Benign	177.693	75,9878%	Trafik berlabel normal
Infilteration	15.620	6,6797%	Ejaan pada artefak dipertahankan
Bot-Stealth	10.123	4,3290%	Bot dengan pola lebih tersembunyi
Bot-Aggressive	10.103	4,3204%	Bot dengan pola lebih agresif
FTP-BruteForce	5.826	2,4914%	Percobaan kredensial FTP

Label	Baris	Proporsi	Arti ringkas
SSH-Bruteforce	5.442	2,3272%	Percobaan kredensial SSH
DoS attacks-SlowHTTPTest	2.755	1,1781%	DoS HTTP lambat
DoS attacks-Slowloris	2.449	1,0473%	DoS koneksi lambat
DDOS attack-HOIC	1.342	0,5739%	DDoS berbasis HOIC
DDOS attack-LOIC-UDP	985	0,4212%	DDoS UDP berbasis LOIC
DoS attacks-GoldenEye	647	0,2767%	DoS HTTP GoldenEye
Brute Force -Web	408	0,1745%	Serangan brute force web
DoS attacks-Hulk	198	0,0847%	DoS HTTP Hulk
Brute Force -XSS	177	0,0757%	Label web/XSS pada artefak
SQL Injection	76	0,0325%	Injeksi SQL



Gambar 6.2. Distribusi label memakai skala log. Jarak ekstrem antarkelas tersembunyi jika memakai skala linear.

4.2 Tugas klasifikasi yang masuk akal

Tugas	Target	Kapan digunakan	Risiko

Tugas	Target	Kapan digunakan	Risiko
Biner	Benign vs serangan	Praktikum awal dan validasi pipeline	Sederhana; tidak membedakan jenis serangan
Keluarga	Benign + 7 keluarga	Analisis operasional yang lebih stabil	Aturan pemetaan harus diumumkan
Granular	15 label	Riset lanjut	Kelas sangat kecil membuat hasil tidak stabil

4.3 Contoh pemetaan tujuh keluarga

Keluarga	Label anggota
Bot	Bot-Stealth; Bot-Aggressive
Infiltration	Infilteration
FTP brute force	FTP-BruteForce
SSH brute force	SSH-Bruteforce
DoS	SlowHTTPTest; Slowloris; GoldenEye; Hulk
DDoS	HOIC; LOIC-UDP
Web attack	Brute Force -Web; Brute Force -XSS; SQL Injection

Pemetaan ini menjelaskan kemungkinan arti “tujuh kategori serangan” pada halaman. Karena artefak tidak menyertakan mapping resmi, tulis aturan ini secara eksplisit jika digunakan.

4.4 Mengapa accuracy menipu

Model yang selalu menjawab Benign memperoleh accuracy sekitar 75,99%, tetapi gagal menangkap semua serangan. Karena itu, gunakan macro-F1, balanced accuracy, recall tiap kelas, dan false-positive rate. Untuk kelas langka, tampilkan pula jumlah kasus absolut.

5. Mengunduh dan membuka dataset

5.1 Persiapan lingkungan

Terminal — membuat lingkungan yang terpisah

```
python -m venv .venv
# Windows: .venv\Scripts\activate
# macOS/Linux: source .venv/bin/activate

python -m pip install --upgrade pip
pip install pandas pyarrow numpy scikit-learn matplotlib seaborn
pip install qiskit-machine-learning==0.9.1
```

Mengapa versi dipatok?

Qiskit berubah cukup cepat. Contoh bab ini diuji dengan qiskit-machine-learning 0.9.1. Jika Anda memakai versi lain, cek migration guide resmi.

5.2 Unduh dan ekstrak

1. Buka halaman Mendeley Data dan tekan Download All.
2. Simpan ZIP di folder proyek, misalnya data/HQC_2026.zip.
3. Ekstrak ZIP. Pastikan tiga berkas Parquet terlihat.
4. Pilih v3 untuk praktikum awal; jangan menggabungkan ketiganya.

5.3 Membaca hanya kolom yang diperlukan

Python — hemat memori dengan column projection

```
from pathlib import Path
import pandas as pd

path = Path("data/SUPER_ENRICHED_hybrid_dataset_v3.parquet")
kolom = ["flow_duration", "flow_pkts/s", "pkt_len_mean",
         "qber", "sifted_key_rate", "label"]

df = pd.read_parquet(path, columns=kolom)
print(df.shape)
print(df.head())
print(df["label"].value_counts())
```

Parquet menyimpan data per kolom. Saat hanya enam kolom diminta, pyarrow tidak perlu memuat semua kolom. Ini berbeda dari CSV yang biasanya harus dipindai sebagai teks.

5.4 Audit schema otomatis

Python — membaca metadata tanpa memuat seluruh tabel

```
import pyarrow.parquet as pq

pf = pq.ParquetFile(path)
print("baris     :", pf.metadata.num_rows)
print("row groups:", pf.metadata.num_row_groups)
print("kolom     :", pf.metadata.num_columns)
print(pf.schema.names)
```

5.5 Kasus khusus timestamp

Python — mengembalikan timestamp dari index

```
base = pd.read_parquet(
    "data/final_hybrid_cybersecurity_dataset.parquet"
)
print(base.index.name)      # timestamp
base = base.reset_index()  # ubah index menjadi kolom biasa
print(base.shape)          # 233844 baris × 89 kolom
```

Kesalahan umum

Jika pandas melaporkan 88 kolom untuk berkas base, bukan berarti satu kolom hilang. Timestamp disimpan sebagai index dan kembali terlihat setelah reset_index().

6. Audit mutu sebelum pemodelan

6.1 Checklist wajib

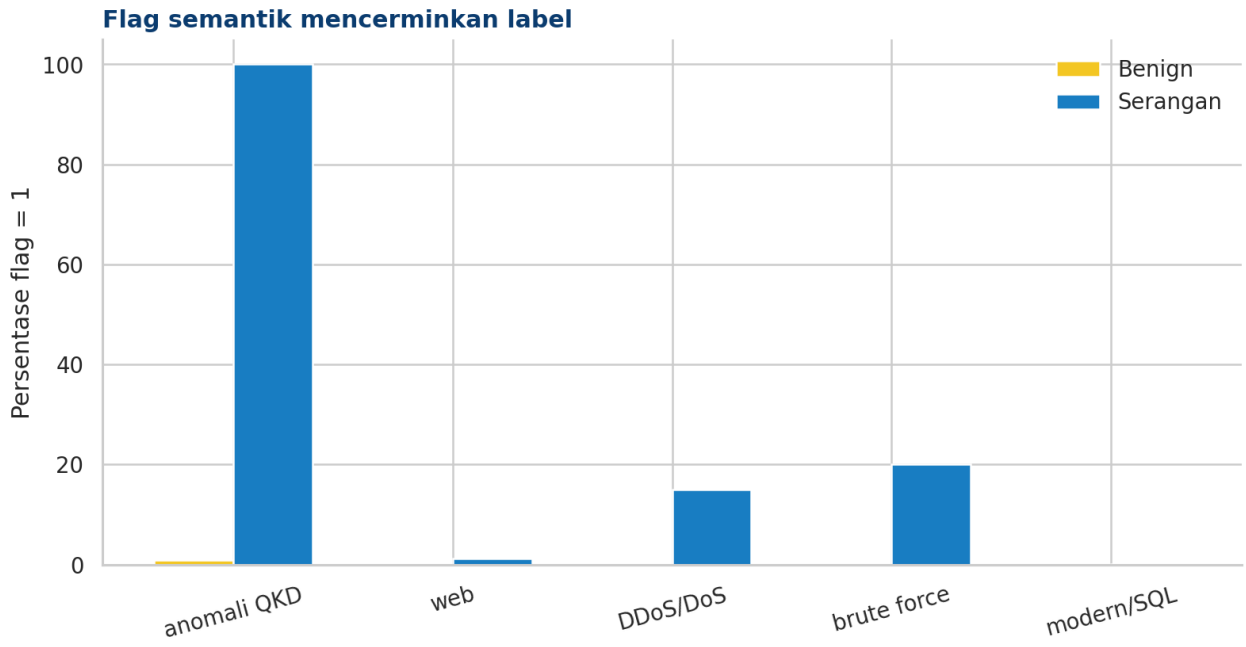
Python — audit minimum

```
import numpy as np

print("shape:", df.shape)
print("duplikat:", df.duplicated().sum())
print("nilai kosong:", df.isna().sum().sum())

numerik = df.select_dtypes(include="number")
print("nilai tak hingga:", np.isinf(numerik.to_numpy()).sum())
print(df["label"].value_counts(normalize=True).mul(100))
```

6.2 Target leakage yang terlihat



Gambar 6.3. Proporsi flag pada kelompok benign dan serangan. Flag semantik dapat mengkodekan target secara langsung.

Kolom	Mengapa berisiko	Tindakan untuk benchmark jujur
is_web_attack_specific	Bernilai 1 hanya untuk tiga label web	Drop
is_ddos_attack	Bernilai 1 untuk label DDoS dan DoS	Drop

Kolom	Mengapa berisiko	Tindakan untuk benchmark jujur
is_bruteforce_attack	Bernilai 1 untuk FTP/SSH brute force	Drop
matches_modern_attack_type	Bernilai 1 hanya untuk SQL Injection	Drop
is_anomalous_qkd	Semua serangan bernilai 1 pada artefak v3	Drop; audit qber secara terpisah
risk flags v4	Dibangun untuk mencerminkan jenis/risiko serangan	Drop pada eksperimen utama; uji pada ablation tersendiri

Aturan emas

Sebuah fitur dianggap bocor jika baru tersedia setelah label diketahui, diturunkan langsung dari label, atau memakai informasi masa depan yang tidak ada saat prediksi nyata.

6.3 Redundansi dan multikolinearitas

- Pilih salah satu dari qber dan fidelity karena hubungannya tepat 1 − qber.
- Jangan memakai qber_delta bersamaan dengan qber; selisihnya selalu 0,01.
- Periksa pasangan mean, max, min, dan variance yang sangat berkorelasi.
- Pemilihan fitur harus dipelajari hanya dari data train agar test set tetap tidak tersentuh.

6.4 Split sebelum sampling atau penyeimbangan

SMOTE menciptakan sampel sintetis dari tetangga. Jika dilakukan sebelum split, sampel train dan test dapat menjadi saudara dekat. Urutan yang benar: split dahulu, fit scaler pada train, lakukan SMOTE hanya pada train, lalu evaluasi test asli.

Urutan salah	Urutan benar
SMOTE → split → scale semua data	Split → fit scaler pada train → transform train/test → SMOTE train saja
Pilih fitur dari semua data	Pilih fitur memakai train saja
Tune model memakai test	Tune memakai validation/CV; test sekali di akhir

6.5 Split acak atau waktu?

Berkas base memuat timestamp 2018-02-14 01:00:00 sampai 2018-03-02 10:29:23. Split waktu lebih mendekati skenario “belajar dari masa lalu, diuji pada masa depan”, tetapi v3/v4 tidak menyimpan timestamp. Untuk studi waktu, gunakan base dan pertahankan index timestamp.

7. Menyiapkan fitur untuk QML

7.1 Mengapa jumlah fitur perlu kecil

Pada feature map sederhana, satu fitur biasanya memakai satu qubit. Memasukkan 95 fitur berarti membutuhkan sirkuit yang sangat besar. Selain itu, quantum kernel untuk n sampel perlu menghitung kira-kira n^2 kemiripan. Praktikum awal sebaiknya memakai 4 fitur dan puluhan sampel per kelas.

Skala latihan	Train	Elemen kernel train	Kegunaan
Mini	48	2.304	Cek instalasi dan alur
Kecil	160	25.600	Eksperimen lokal yang lebih stabil
Menengah	1.000	1.000.000	Mulai mahal pada simulator
Penuh	>200.000	>40 miliar	Tidak realistis untuk QSVC langsung

7.2 Set fitur latihan yang transparan

Fitur	Alasan	Catatan
qber	Mewakili kanal QKD	Berpotensi terikat label; gunakan untuk demonstrasi, bukan klaim deployment
sifted_key_rate	Indikator QKD kedua yang tidak deterministik terhadap qber	Tetap fitur simulasi
flow_pkts/s	Kecepatan paket	Skala sangat lebar
pkt_len_mean	Ukuran paket rata-rata	Fitur aliran klasik

Untuk benchmark ketat, buat dua jalur: (A) klasik saja tanpa QKD, dan (B) klasik + qber + sifted_key_rate. Perbedaan kinerja menunjukkan nilai tambah fitur, tetapi belum membuktikan keunggulan komputasi kuantum.

7.3 Normalisasi sudut

Gerbang rotasi memakai sudut. MinMaxScaler memetakan tiap fitur ke rentang [0, π]. Scaler wajib di-fit pada train. Nilai test boleh sedikit keluar dari rentang jika berada di luar minimum/maksimum train; itu lebih jujur daripada melihat test saat fitting.

Python — skala untuk angle encoding

```
from sklearn.preprocessing import MinMaxScaler
import numpy as np

scaler = MinMaxScaler(feature_range=(0, np.pi))
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

7.4 Feature map dan quantum kernel

Feature map $U\phi(x)$ mengubah vektor x menjadi keadaan $|\phi(x)\rangle$. Quantum kernel menghitung $K(x,z)=|\langle\phi(x)|\phi(z)\rangle|^2$. QSVC memakai matriks kernel ini di dalam optimasi SVM klasik.

Komponen	Peran
zz_feature_map	Mengkodekan fitur melalui rotasi dan interaksi ZZ
FidelityQuantumKernel	Mengestimasi kemiripan dua keadaan kuantum
QSVC	Melatih support vector classifier menggunakan quantum kernel
Simulator	Menghitung sirkuit tanpa perangkat keras kuantum

8. Praktikum utama: SVM klasik vs QSVC

Target praktikum

Klasifikasi biner Benign vs Serangan dengan 4 fitur, train/test yang sama, dan sampel kecil agar simulator selesai dalam waktu wajar.

8.1 Muat dan bagi data

Langkah 1 — split dulu, sampling kemudian

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split

FILE = "data/SUPER_ENRICHED_hybrid_dataset_v3.parquet"
FEATURES = ["qber", "sifted_key_rate", "flow_pkts/s", "pkt_len_mean"]

df = pd.read_parquet(FILE, columns=FEATURES + ["label"])
df = df.replace([np.inf, -np.inf], np.nan).dropna()
df["target"] = (df["label"] != "Benign").astype(int)

train_pool, test_pool = train_test_split(
    df, test_size=0.20, stratify=df["target"], random_state=42
)

def sample_each(frame, n, seed):
    return (frame.groupby("target", group_keys=False)
            .sample(n=n, random_state=seed)
            .sample(frac=1, random_state=seed))

train = sample_each(train_pool, 24, 42)
test = sample_each(test_pool, 12, 43)
```

8.2 Scaling dan baseline klasik

Langkah 2 — baseline RBF-SVM

```
from sklearn.preprocessing import MinMaxScaler
from sklearn.svm import SVC
```

```
X_train = train[FEATURES].to_numpy()
y_train = train["target"].to_numpy()
X_test = test[FEATURES].to_numpy()
y_test = test["target"].to_numpy()

scaler = MinMaxScaler(feature_range=(0, np.pi))
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

classical = SVC(kernel="rbf", class_weight="balanced")
classical.fit(X_train, y_train)
pred_classical = classical.predict(X_test)
```

8.3 Quantum kernel dan QSVC

Langkah 3 — model quantum kernel pada simulator

```
from qiskit.circuit.library import zz_feature_map
from qiskit_machine_learning.kernels import FidelityQuantumKernel
from qiskit_machine_learning.algorithms import QSVC

feature_map = zz_feature_map(
    feature_dimension=len(FEATURES), reps=1, entanglement="linear"
)
quantum_kernel = FidelityQuantumKernel(feature_map=feature_map)
qsvc = QSVC(quantum_kernel=quantum_kernel)
qsvc.fit(X_train, y_train)
pred_quantum = qsvc.predict(X_test)
```

8.4 Evaluasi yang sama

Langkah 4 — metrik dan confusion matrix

```
from sklearn.metrics import (
    balanced_accuracy_score, classification_report,
    confusion_matrix, f1_score
)

for nama, pred in {
    "RBF-SVM": pred_classical,
    "QSVC": pred_quantum,
}.items():
    print("\n", nama)
    print("balanced accuracy:", balanced_accuracy_score(y_test, pred))
    print("macro-F1:", f1_score(y_test, pred, average="macro"))
    print(confusion_matrix(y_test, pred))
    print(classification_report(y_test, pred,
          target_names=["Benign", "Serangan"], digits=3))
```

Cara menafsirkan

Dengan sampel sangat kecil, skor dapat berubah besar ketika seed berubah. Tujuan pertama adalah memvalidasi pipeline. Naikkan ukuran secara bertahap dan ulangi beberapa seed sebelum membandingkan model.

8.5 Lima pemeriksaan jika hasil terlalu bagus

1. Pastikan flag semantik dan fitur risiko tidak masuk ke X.
2. Pastikan sampling/SMOTE tidak dilakukan sebelum split.

3. Pastikan scaler hanya fit pada train.
4. Ulangi tanpa qber untuk melihat seberapa besar target dipisahkan fitur QKD buatan.
5. Uji pada split waktu atau sumber data berbeda; random split saja dapat membagi pola yang sangat mirip.

9. Eksperimen yang menjawab pertanyaan ilmiah

9.1 Ablation study

Eksperimen	Fitur	Pertanyaan
A	4 fitur klasik	Seberapa jauh data jaringan saja bekerja?
B	qber + sifted_key_rate	Apakah QKD simulasi sendiri memisahkan kelas?
C	4 klasik + 2 QKD	Apakah QKD menambah nilai prediktif?
D	C + flag semantik	Seberapa besar skor melonjak karena leakage? Gunakan hanya sebagai demonstrasi jebakan.
E	C pada RBF-SVM dan QSVC	Apakah perbedaan datang dari model atau dari fitur?

9.2 Pengujian berulang

Jalankan minimal 5–10 seed. Laporkan mean ± standard deviation untuk macro-F1 dan balanced accuracy. Jika selisih model lebih kecil daripada variasi antar-seed, tidak ada bukti kuat bahwa satu model lebih baik.

9.3 Kompleksitas sebagai metrik

Metrik	Mengapa dicatat
Waktu fit	Quantum kernel dapat jauh lebih lambat dari baseline klasik
Waktu prediksi	Penting untuk NIDS yang mendekati waktu nyata
Jumlah evaluasi sirkuit	Menggambarkan biaya kuantum/simulator
Jumlah qubit dan depth	Menunjukkan kelayakan perangkat keras
Ukuran train	Skor tanpa skala data tidak dapat dibandingkan

9.4 Kapan boleh menyebut keunggulan kuantum?

- Ada baseline klasik kuat dan tuning yang sebanding.
- Data train/test serta fitur identik, kecuali komponen yang memang diuji.
- Keuntungan bertahan pada beberapa seed dan split yang lebih realistis.
- Biaya komputasi, jumlah circuit shots, qubit, depth, dan noise dilaporkan.
- Dataset tidak memiliki fitur yang secara langsung mengkodekan target.

- Hasil direplikasi pada dataset atau lingkungan lain.

Kesimpulan yang aman

"QSVC memberi hasil X pada subset Y dengan feature map Z" adalah pernyataan terukur. "Dataset ini membuktikan quantum advantage" tidak didukung oleh satu eksperimen kecil.

9.5 VQC sebagai jalur lanjut

Variational Quantum Classifier memakai sirkuit berparameter dan optimizer. VQC menambah risiko barren plateau, local minima, dan waktu training. Pelajari QSVC lebih dulu; setelah pipeline stabil, gunakan VQC pada subset dan fitur yang sama agar perbandingan tetap adil.

Opsional — titik awal VQC

```
# Sketsa minimal; uji versi API sebelum riset penuh
from qiskit.circuit.library import zz_feature_map, real_amplitudes
from qiskit_machine_learning.algorithms import VQC

vqc = VQC(
    feature_map=zz_feature_map(4, reps=1, entanglement="linear"),
    ansatz=real_amplitudes(4, reps=1),
)
vqc.fit(X_train, y_train)
pred_vqc = vqc.predict(X_test)
```

10. Kesalahan umum dan cara memperbaikinya

Gejala	Kemungkinan sebab	Perbaikan
MemoryError	Memuat semua kolom/berkas	Gunakan columns=, pilih satu berkas, atau pyarrow batch
QSVC sangat lama	Terlalu banyak sampel/qubit	Mulai 48 train dan 4 fitur; naikkan bertahap
Accuracy tinggi sekali	Ketidakseimbangan atau leakage	Periksa macro-F1; drop flag semantik; ablation qber
Kolom timestamp hilang	Menjadi pandas index	reset_index() pada berkas base
Jumlah kolom berbeda	Memakai base, v3, atau v4 yang berbeda	Cetak nama file, shape, dan schema
Import Qiskit gagal	Versi lingkungan tidak kompatibel	Buat venv baru; pasang qiskit-machine-learning==0.9.1
Skor berubah drastis	Subset terlalu kecil	Ulangi seed dan laporkan variasi
Multiclass gagal	Kelas langka terlalu sedikit	Mulai biner/family; stratifikasi; jangan paksa split besar

10.1 Checklist laporan

- DOI, versi, tanggal akses, nama file, SHA-256, jumlah baris dan kolom.
- Definisi target dan mapping label.

- Daftar fitur yang digunakan dan yang dibuang karena leakage.
- Aturan split, seed, ukuran train/validation/test, serta setiap sampling/SMOTE.
- Scaler, feature map, qubit, reps, entanglement, backend/simulator, shots jika ada.
- Baseline klasik, hyperparameter, metrik per kelas, mean ± std, waktu komputasi.
- Keterbatasan: data simulasi, schema yang tidak selaras dengan ringkasan, dan tidak adanya file QASM di ZIP yang diperiksa.

10.2 Etika dan batas penggunaan

Gunakan dataset untuk pendidikan dan penelitian defensif. Jangan menganggap model siap produksi hanya karena akurat pada data benchmark. Deployment NIDS memerlukan validasi pada trafik organisasi, perubahan distribusi, privasi, alarm palsu, audit keamanan, dan jalur respons insiden.

Lisensi CC BY 4.0 mengizinkan penggunaan dan adaptasi dengan atribusi. Cantumkan sitasi dataset dan tandai setiap perubahan, subset, mapping label, atau fitur turunan yang Anda buat.

11. Proyek akhir mini

Buat laporan 4–6 halaman yang membandingkan tiga eksperimen: klasik saja, klasik + dua fitur QKD, dan quantum kernel dengan fitur yang sama. Gunakan minimal lima seed.

11.1 Pertanyaan proyek

1. Apakah qber dan sifted_key_rate menambah macro-F1 dibanding fitur klasik saja?
2. Apakah QSVC mengungguli RBF-SVM setelah fitur, data, dan split disamakan?
3. Seberapa besar variasi skor antar-seed?
4. Apa yang terjadi ketika is_anomalous_qkd ditambahkan? Jelaskan mengapa lonjakan skor tidak selalu baik.
5. Apakah kesimpulan berubah pada split waktu berkas base?

11.2 Rubrik

Aspek	Bobot	Kriteria
Reproduksibilitas	20%	File, hash, seed, split, dan versi paket lengkap
Audit leakage	25%	Fitur berisiko dikenali dan diuji melalui ablation
Keadilan perbandingan	20%	Data dan fitur identik antar-model
Evaluasi	20%	Macro-F1, balanced accuracy, confusion matrix, waktu
Interpretasi	15%	Kesimpulan sesuai bukti; keterbatasan jelas

11.3 Pertanyaan refleksi

- Jika fitur QBER dibuat dari label serangan, apa sebenarnya yang dipelajari model?
- Apakah subset seimbang mencerminkan kondisi jaringan nyata?

- Mana yang lebih penting untuk NIDS: recall serangan atau false-positive rate? Siapa yang menanggung akibatnya?
- Bagaimana menguji apakah pola bertahan pada organisasi, hari, atau sensor lain?

Lampiran A. Kamus kolom klasik

Keluarga	Kolom	Makna
Identitas	dst_port; protocol	Port tujuan dan nomor protokol. Nilai pecahan menunjukkan data mungkin telah diagregasi.
Durasi	flow_duration	Durasi aliran; satuan tidak dijelaskan di arsip, lazimnya mikrodetik pada CICFlowMeter.
Jumlah paket	tot_fwd_pkts; tot_bwd_pkts	Jumlah paket arah forward dan backward.
Total byte	totlen_fwd_pkts; totlen_bwd_pkts	Total panjang paket per arah.
Panjang paket forward	fwd_pkt_len_max; fwd_pkt_len_min; fwd_pkt_len_mean; fwd_pkt_len_std	Ringkasan panjang paket arah forward.
Panjang paket backward	bwd_pkt_len_max; bwd_pkt_len_min; bwd_pkt_len_mean; bwd_pkt_len_std	Ringkasan panjang paket arah backward.
Laju aliran	flow_byts/s; flow_pkts/s	Byte dan paket per detik untuk keseluruhan aliran.
IAT aliran	flow_iat_mean; flow_iat_std; flow_iat_max; flow_iat_min	Inter-arrival time antar-paket untuk aliran.
IAT forward	fwd_iat_tot; fwd_iat_mean; fwd_iat_std; fwd_iat_max; fwd_iat_min	Jeda waktu paket arah forward.
IAT backward	bwd_iat_tot; bwd_iat_mean; bwd_iat_std; bwd_iat_max; bwd_iat_min	Jeda waktu paket arah backward.
Flag per arah	fwd_psh_flags; bwd_psh_flags; fwd_urg_flags; bwd_urg_flags	Jumlah/indikator flag PSH dan URG per arah.
Header	fwd_header_len; bwd_header_len	Total panjang header per arah.
Laju per arah	fwd_pkts/s; bwd_pkts/s	Paket per detik untuk masing-masing arah.
Panjang paket gabungan	pkt_len_min; pkt_len_max; pkt_len_mean; pkt_len_std; pkt_len_var	Statistik ukuran paket dua arah.
Flag TCP	fin_flag_cnt; syn_flag_cnt; rst_flag_cnt; psh_flag_cnt; ack_flag_cnt; urg_flag_cnt; cwe_flag_count; ece_flag_cnt	Jumlah flag sesi. Nama cwe dipertahankan seperti schema.
Rasio dan ukuran	down/up_ratio; pkt_size_avg; fwd_seg_size_avg; bwd_seg_size_avg	Rasio down/up dan ukuran paket/segmen rata-rata.
Bulk forward	fwd_byts/b_avg; fwd_pkts/b_avg; fwd_blk_rate_avg	Rata-rata byte, paket, dan laju bulk forward.
Bulk backward	bwd_byts/b_avg; bwd_pkts/b_avg; bwd_blk_rate_avg	Rata-rata byte, paket, dan laju bulk backward.
Subflow	subflow_fwd_pkts; subflow_fwd_byts; subflow_bwd_pkts; subflow_bwd_byts	Jumlah paket dan byte dalam subflow.
Window	init_fwd_win_byts; init_bwd_win_byts	Ukuran initial TCP window per arah.
Aktivitas forward	fwd_act_data_pkts; fwd_seg_size_min	Paket forward yang membawa data dan ukuran segmen minimum.
Active	active_mean; active_std; active_max; active_min	Durasi periode aktif.
Idle	idle_mean; idle_std; idle_max; idle_min	Durasi periode idle.

Lampiran B. Kamus fitur pengayaan

Kolom	Interpretasi operasional
qber	Tingkat error bit kuantum; rentang v3 0–0,23656.
sifted_key_rate	Laju/proposi sifted key; rentang v3 0,28320–0,38086.
fidelity	Tepat 1 − qber pada v3.
qber_delta	Tepat qber − 0,01 pada v3.
is_anomalous_qkd	Flag ambang QBER; pada v3 berubah menjadi 1 di atas sekitar 0,02.
is_web_attack_specific	Flag label web; berisiko target leakage.
is_ddos_attack	Flag label DoS/DDoS; berisiko target leakage.
is_bruteforce_attack	Flag label FTP/SSH brute force; berisiko target leakage.
matches_modern_attack_type	Flag SQL Injection pada artefak; berisiko target leakage.
payload_entropy	Indikator entropy payload; hanya dua nilai unik pada artefak.
special_char_count	Jumlah karakter khusus; hanya dua nilai unik pada artefak.
qber_rolling_mean_10s / std	Rata-rata dan simpangan baku QBER pada jendela 10 detik.
fwd_pkts_rolling_sum_10s / std	Jumlah dan simpangan baku paket forward pada jendela 10 detik.
flow_duration_rolling_mean_10s / std	Rata-rata dan simpangan baku durasi aliran pada jendela 10 detik.
is_reconnaissance	Flag dugaan reconnaissance pada v4.
is_mitm_suspicious	Flag dugaan man-in-the-middle pada v4.
is_exfiltration_suspicious	Flag dugaan exfiltration pada v4.
data_exfil_risk	Skor risiko eksfiltrasi pada v4.
recon_risk	Skor risiko reconnaissance pada v4.
bruteforce_risk	Skor risiko brute force pada v4.
ddos_risk	Skor risiko DoS/DDoS pada v4.
quantum_channel_instability	Skor ketidakstabilan kanal kuantum pada v4.
label	Target kelas; bukan fitur input.
timestamp	Index waktu pada berkas base; tidak ada pada v3/v4.

Lampiran C. Reproduksibilitas artefak

Berkas	SHA-256
final_hybrid_cybersecurity_dataset.parquet	e1d49d73f4942bae20d8262dc03d38a4668119ee43375de42a7d1119ee6f9aedce
SUPER_ENRICHED_hybrid_dataset_v3.parquet	aa2aefc0e8586c56e315a36b6c9fa922f36b5c21c3390bf5c2ea2eeab9995ec1

Berkas	SHA-256
HQC20_Super_Enriched_Dataset_v4.parquet	cdd7ce5d679955d8c19279b2a52a4f4562e2a35f551ab73043f34e0ec6aaab43

Memeriksa checksum

```
# macOS/Linux
sha256sum data/*.parquet

# Windows PowerShell
Get-FileHash data\*.parquet -Algorithm SHA256
```

Lampiran D. Glosarium

Istilah	Arti
Ablation study	Eksperimen dengan menambah atau menghapus kelompok fitur untuk mengukur kontribusinya.
Balanced accuracy	Rata-rata recall tiap kelas; lebih tahan terhadap ketidakseimbangan.
BB84	Protokol QKD yang memakai pilihan basis pengukuran untuk membentuk kunci.
Feature map	Transformasi data klasik menjadi keadaan kuantum.
Fidelity	Kemiripan antara keadaan kuantum; pada dataset ini juga kolom 1 − QBER.
Kernel	Fungsi kemiripan yang membantu model menemukan batas pemisah nonlinier.
Macro-F1	Rata-rata F1 tiap kelas dengan bobot sama.
NIDS	Sistem pendeteksi intrusi jaringan.
Parquet	Format kolumnar terkompresi untuk data tabular.
QBER	Proporsi error pada bit kunci kuantum.
QKD	Distribusi kunci kriptografi dengan prinsip mekanika kuantum.
QSVC	Support Vector Classifier yang menggunakan quantum kernel.
SMOTE	Metode membuat sampel minoritas sintetis dari tetangga.
Target leakage	Informasi tentang target masuk ke fitur atau proses training secara tidak sah.
VQC	Klasifikator kuantum variational dengan parameter yang dioptimasi.

Referensi

1. Islam, I., Rabbi, I. R., Emon, T. H., Sahin Afridi, A., & Nur, F. (2026). A Hybrid Quantum-Classical Network Intrusion Detection Dataset (Version 1). Mendeley Data. https://doi.org/10.17632/68rc9crgkj.1

2. Qiskit Machine Learning Development Team. Getting Started, Quantum Kernel Machine Learning, dan Training a Quantum Model on a Real Dataset. Dokumentasi versi 0.9.1, diakses 13 Oktober 2026.

3. Institut Teknologi Sepuluh Nopember. Panduan Identitas Visual. https://www.its.ac.id/tentang/panduan-identitas-visual/

4. Catatan inspeksi penulis: arsip Mendeley Version 1 diunduh dan schema Parquet dihitung langsung pada 13 Oktober 2026. Angka distribusi, relasi fitur, ukuran, dan hash pada bab ini berasal dari artefak tersebut.