Institut Teknologi Sepuluh Nopember

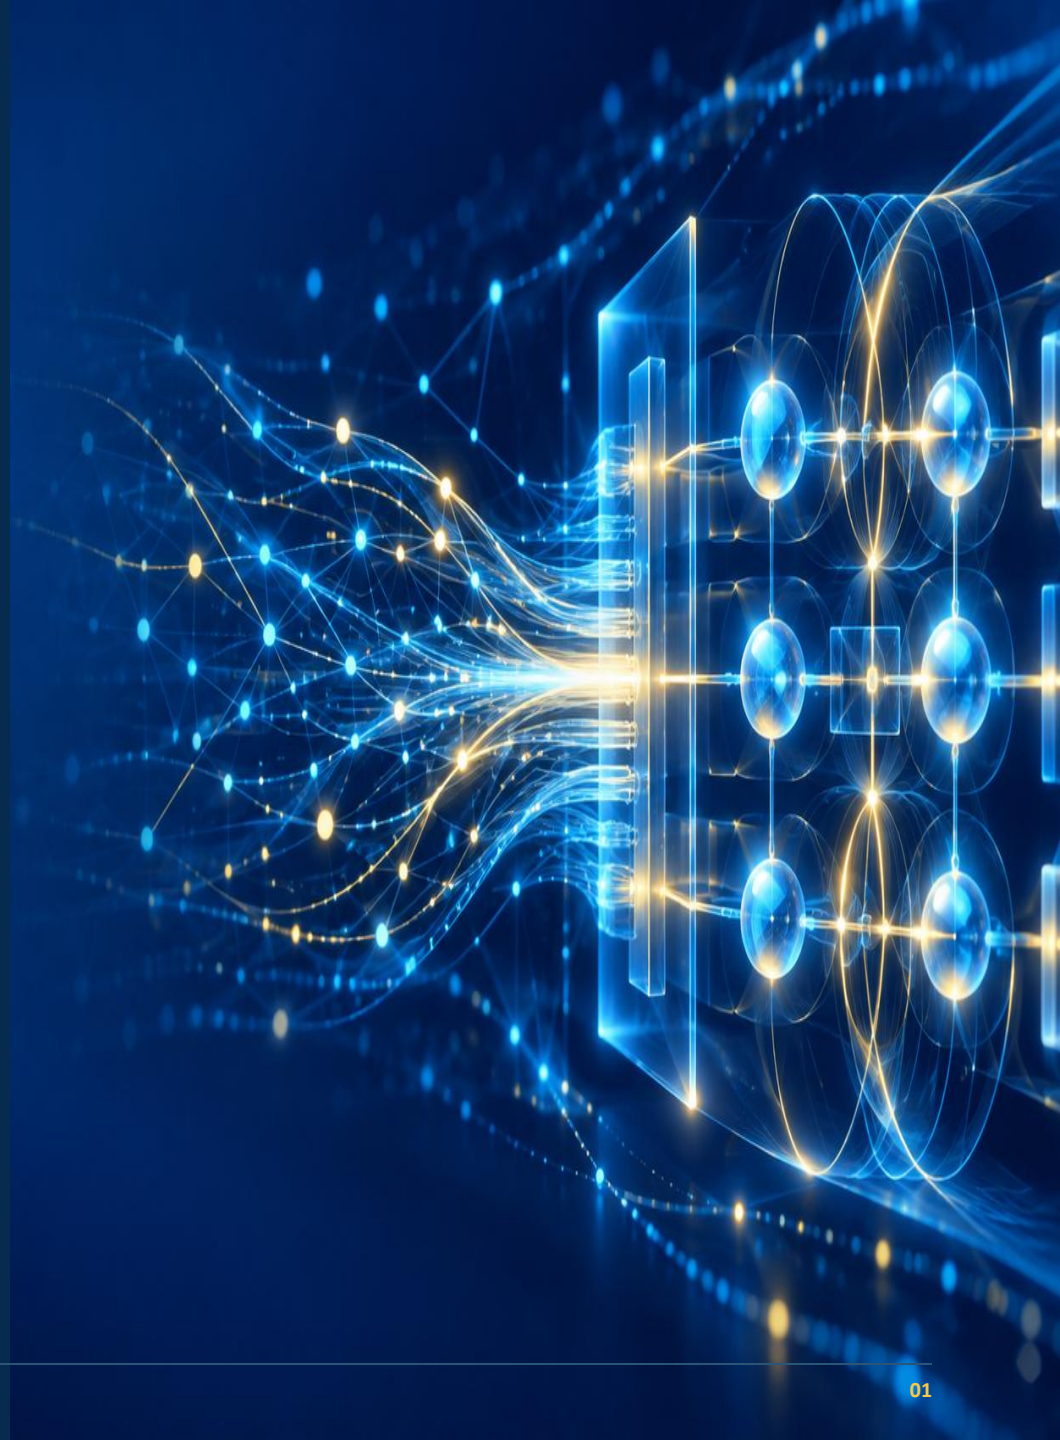
BUKU AJAR • BAB 6

Memahami Dataset HQC-2026

Dari data keamanan siber menuju Quantum Machine Learning

Hatma Suryotrisongko

Institut Teknologi Sepuluh Nopember



Target belajar bab ini

1 • Memahami

Menjelaskan paket jaringan, label serangan, fitur QKD, dan isi tiga file Parquet.

2 • Mengaudit

Memeriksa bentuk data, ketidakseimbangan kelas, nilai hilang, duplikasi, dan kebocoran target.

3 • Mempraktikkan

Membangun baseline SVM dan eksperimen quantum kernel yang kecil, terukur, dan dapat direproduksi.

Pertanyaan utama

Apakah model belajar pola keamanan yang masuk akal, atau hanya membaca fitur yang dibuat dari label?

Dari paket jaringan ke keputusan model



QML dimulai setelah data dipilih, dibersihkan, dibagi, dan diskalakan. Komputer kuantum bukan pengganti audit data.

QKD dan BB84 dalam bahasa sederhana

Kanal kuantum

Alice dan Bob bertukar keadaan kuantum untuk membangun kunci. Pengukuran yang salah atau penyadapan dapat menaikkan tingkat galat.

Intuisi

QBER

Quantum Bit Error Rate adalah proporsi bit yang tidak cocok. Makin tinggi QBER, makin tidak stabil atau mencurigakan kanalnya.

ukur galat

HQC-2026

Dataset menggabungkan ciri traffic jaringan klasik dengan ciri terinspirasi QKD, seperti qber, fidelity, dan indikator anomali kanal.

gabungkan

Identitas dataset

HQC-2026

Hybrid Quantum–Classical Cybersecurity Dataset

DOI 10.17632/68rc9crgkj.1

CC BY 4.0

9 Jan 2026

Penulis

Iftekharul Islam
Ibrahim Reza Rabbi
Tasfiqul Hasnat Emon
Arafat Sahin Afridi
Fernaz Nur

Lisensi terbuka tetap mewajibkan atribusi.

Halaman publik dan artefak rilis tidak sepenuhnya sama

Aspek	Klaim halaman	Temuan pada ZIP versi 1
Jumlah sampel	14,69 juta	233.844 baris per file
Keseimbangan	Perfectly balanced / SMOTE	Label v3 dan v4 sangat tidak seimbang
Dimensi	89 klasik + 7 quantum-inspired	v3: 96 kolom termasuk label; v4: 104
OpenQASM	Sirkuit dapat direproduksi	Tidak ada file .qasm di ZIP yang diunduh

Prinsip kerja ilmiah: laporkan apa yang benar-benar ada di artefak yang Anda pakai. Simpan versi, tanggal akses, dan checksum.

Tiga file Parquet di dalam rilis

File	Baris	Kolom	Label	Kegunaan
final_hybrid_cybersecurity_dataset.parquet	233.844	89*	14	Basis + timestamp; Bot belum dipecah
SUPER_ENRICHED_hybrid_dataset_v3.parquet	233.844	96	15	Pilihan utama untuk tutorial
HQC20_Super_Enriched_Dataset_v4.parquet	233.844	104	15	Tambahan skor risiko dan indikator

*Pada pembacaan pandas, timestamp muncul sebagai index sehingga tampak 88 kolom sampai reset_index().

Jangan menggabungkan ketiga file secara vertikal. Isinya adalah versi transformasi dari observasi yang sama.

File mana yang sebaiknya dipakai?

Mulai dari v3

Struktur cukup kaya, 15 label, dan ukuran masih realistis untuk eksplorasi. Ini pilihan utama latihan bab.

Gunakan base bila

Anda perlu timestamp untuk split temporal atau ingin menelusuri fitur sebelum pengayaan. Ingat: label Bot belum dipecah.

Gunakan v4 bila

Anda ingin menguji fitur skor risiko tambahan. Wajib lakukan ablation karena sebagian fitur dapat terlalu dekat dengan label.

Rekomendasi kelas: v3 → audit → baseline klasik → subset QML kecil.

Satu baris = satu observasi traffic

ALAMAT & PORT	STATISTIK FLOW	FLAG TCP	FITUR QKD	LABEL	
Source IP Destination IP Ports	Durasi Bytes Paket IAT	SYN ACK RST FIN	qber fidelity basis	Benign atau jenis serangan	Model membaca kolom input X untuk menebak label y.

Hapus pengenal mentah yang tidak stabil. Jangan biarkan label atau turunannya masuk ke X.

Keluarga fitur klasik

Keluarga	Contoh	Makna sederhana
Flow	duration, fwd/bwd packets	Lama dan arah percakapan
Ukuran	packet length, bytes/s	Banyaknya data yang lewat
Waktu	IAT mean/max/min	Jarak waktu antar paket
TCP	SYN, ACK, RST, FIN	Keadaan dan pola koneksi
Aktivitas	active/idle stats	Kapan flow sibuk atau diam
Konteks	ports, protocol, flags	Jenis layanan dan perilaku jaringan

Fitur quantum-inspired dan fitur pengayaan

Kelompok	Contoh	Pertanyaan audit
Kualitas kanal	qber, fidelity	Apakah nilai berasal dari pengukuran atau konstruksi?
Basis/protokol	basis, protocol	Bagaimana kategori dikodekan menjadi angka?
Anomali QKD	is_anomalous_qkd	Apakah ini sudah mengungkap label?
Payload	payload_entropy	Apakah ekstraksi payload realistis saat inferensi?
Rolling	rolling_*	Apakah window memakai data masa depan?
Skor risiko v4	ddos_risk, recon_risk	Apakah skor dibuat memakai label target?

Tiga relasi yang harus Anda kenali

Fidelity

fidelity = 1 − qber

Informasinya berulang. Memakai keduanya dapat memberi bobot ganda pada konsep yang sama.

QBER delta

qber_delta = qber − 0,01

Ini hanya pergeseran skala, bukan informasi baru.

Ambang anomali

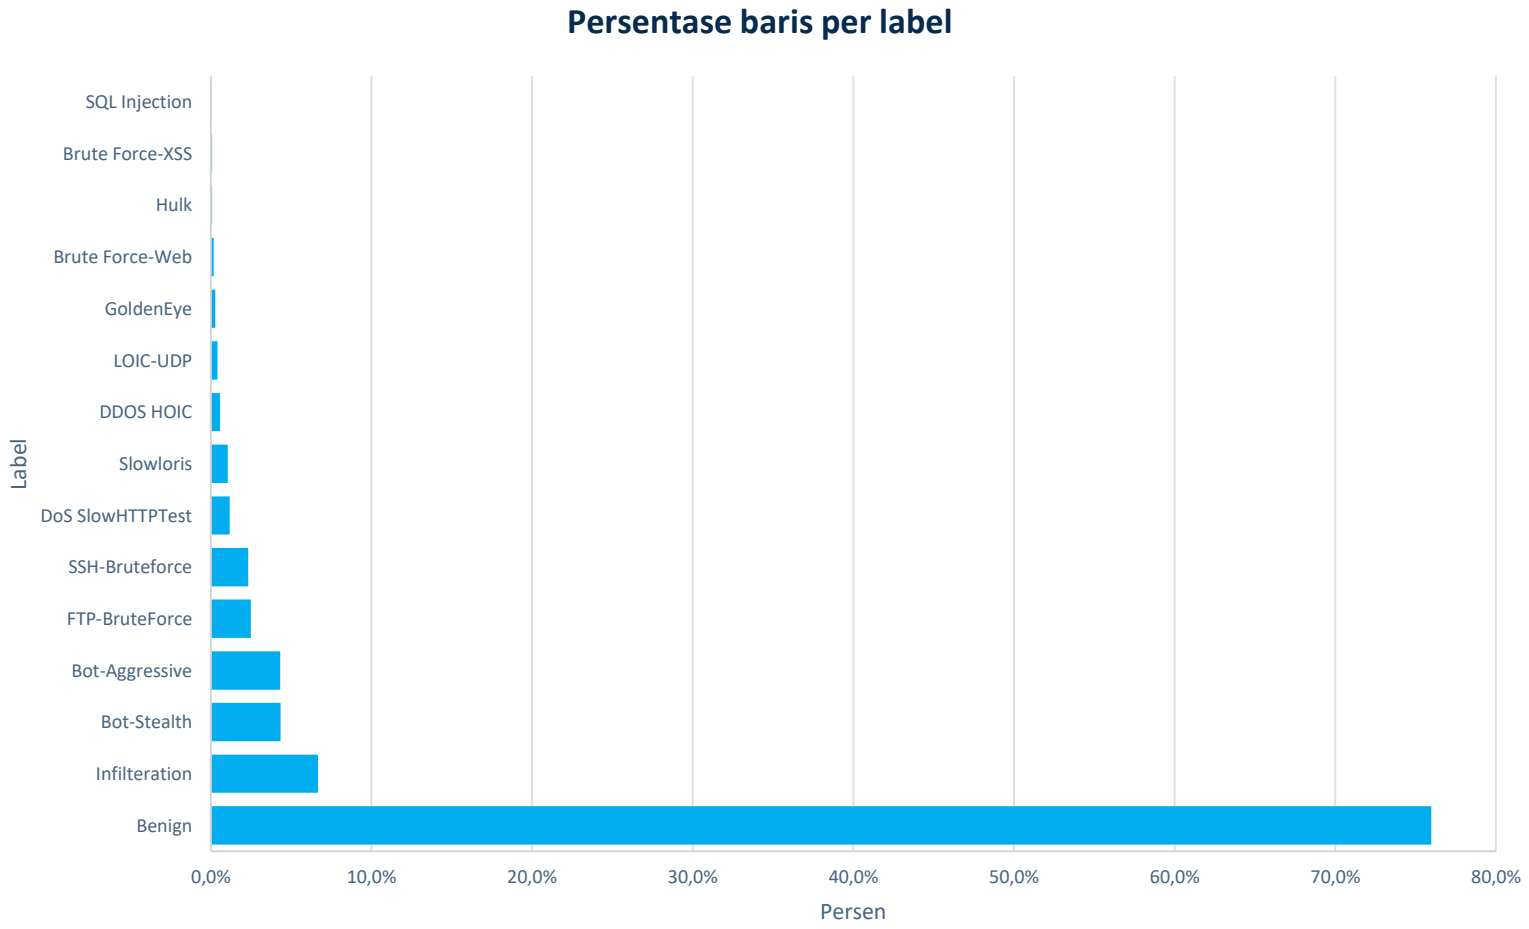
is_anomalous_qkd berubah pada qber sekitar 0,02.

Fitur biner ini dapat menjadi jalan pintas bagi model.

Fitur berkorelasi bukan selalu salah.

Namun kita harus menguji apakah performa bertahan ketika fitur turunan dan indikator risiko dihapus.

Distribusi 15 label pada v3 dan v4



Apa artinya?

- Benign mendominasi sekitar 76%.
- Kelas terkecil hanya puluhan hingga ratusan baris.
- Accuracy mudah terlihat tinggi walau kelas kecil gagal dikenali.
- Gunakan stratified split dan macro-F1.

Dari 15 label ke 7 keluarga serangan

Keluarga	Contoh label granular
Benign	Benign
Botnet	Bot-Stealth, Bot-Aggressive
Brute force	FTP-BruteForce, SSH-Bruteforce
DoS/DDoS	SlowHTTPTest, Slowloris, HOIC, LOIC-UDP, GoldenEye, Hulk
Web	Brute Force-Web, Brute Force-XSS, SQL Injection
Infiltration	Infilteration
Catatan	Ejaan label asli perlu dipertahankan untuk reproduksibilitas

Mengapa accuracy dapat menipu

Model malas

Jika selalu menebak Benign, model sudah mendapat accuracy sekitar

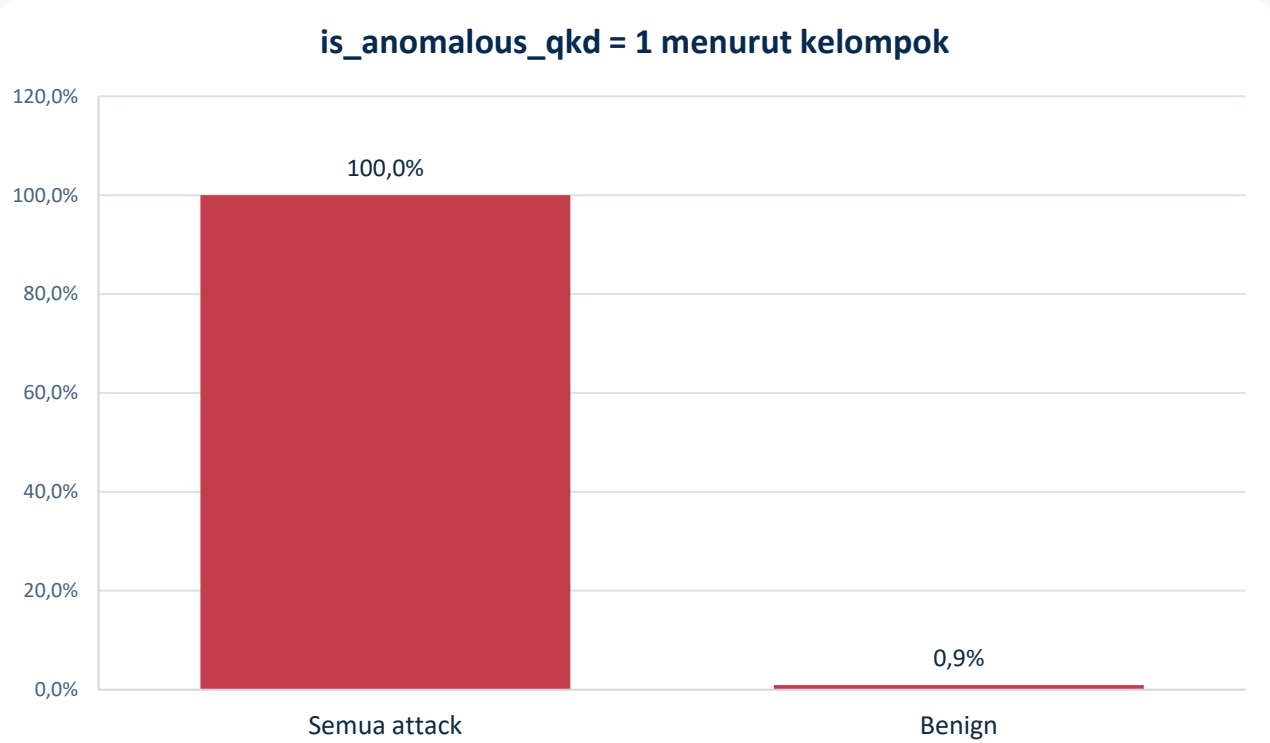
76%

tetapi tidak berguna untuk mendeteksi serangan

Gunakan metrik ini

- Macro-F1: semua kelas mendapat bobot sama.
- Balanced accuracy: rata-rata recall antarkelas.
- Recall serangan: berapa banyak attack yang tertangkap.
- Confusion matrix: kelas mana yang tertukar.
- PR-AUC: cocok saat kelas positif jarang.

Audit kebocoran target: temuan paling penting



Risiko

Indikator ini hampir mengungkap jawaban. Model dapat terlihat hebat tanpa mempelajari pola traffic.

Uji dua versi: dengan dan tanpa fitur yang dibangun dari label, anomaly flag, dan skor risiko.

BAGIAN PRAKTIK

Eksperimen yang jujur lebih penting daripada skor tinggi

Split dahulu. Fit transformasi hanya pada data latih. Simpan seed. Bandingkan dengan baseline klasik.

SPLIT SCALE TRAIN TEST

Siapkan lingkungan Python

```
python -m venv .venv

# Windows
.venv\Scripts\activate

# macOS / Linux
source .venv/bin/activate

pip install pandas pyarrow scikit-learn matplotlib
pip install qiskit qiskit-machine-learning
```

Checklist

- Python 3.10+
- RAM cukup untuk file penuh
- Mulai dari sampel kecil
- Catat versi paket
- Gunakan seed tetap

Versi tutorial diuji dengan qiskit-machine-learning 0.9.1.

Baca Parquet dan audit cepat

```
import pandas as pd

path = "SUPER_ENRICHED_hybrid_dataset_v3.parquet"
df = pd.read_parquet(path)

print(df.shape)                  # (233844, 96)
print(df["label"].value_counts())
print("missing:", df.isna().sum().sum())
print("duplicates:", df.duplicated().sum())
print(df.dtypes.value_counts())
```

Hasil inspeksi rilis

233.844

baris

0

missing dan full-row duplicate

≈182 MiB

memori saat v3 dimuat

Mulai dengan tugas biner dan subset yang terkontrol

```
from sklearn.model_selection import train_test_split

FEATURES = [
    "Flow Duration", "Total Fwd Packets",
    "Total Backward Packets", "Flow Bytes/s"
]

work = df[FEATURES + ["label"]].dropna().copy()
work["target"] = (work["label"] != "Benign").astype(int)

# Untuk demo QML: ambil sampel seimbang kecil
pos = work[work.target == 1].sample(120, random_state=42)
neg = work[work.target == 0].sample(120, random_state=42)
small = pd.concat([pos, neg]).sample(frac=1, random_state=42)
```

Mengapa kecil?

- Kernel kuantum membutuhkan banyak evaluasi pasangan sampel.
- Simulasi dapat tumbuh mahal.
- Subset kecil cocok untuk belajar alur kerja.
- Hasil demo bukan bukti keunggulan kuantum.

Skalakan fitur menjadi sudut

```
import numpy as np
from sklearn.preprocessing import MinMaxScaler

X = small[FEATURES].to_numpy()
y = small["target"].to_numpy()

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, stratify=y, random_state=42
)

scaler = MinMaxScaler(feature_range=(0, np.pi))
X_train_s = scaler.fit_transform(X_train)
X_test_s  = scaler.transform(X_test)
```

Aturan emas

fit pada train

transform pada test

Jika scaler melihat test set, informasi masa depan bocor ke proses pelatihan.

Bangun baseline klasik terlebih dahulu

```
from sklearn.svm import SVC
from sklearn.metrics import classification_report

rbf = SVC(kernel="rbf", class_weight="balanced")
rbf.fit(X_train_s, y_train)

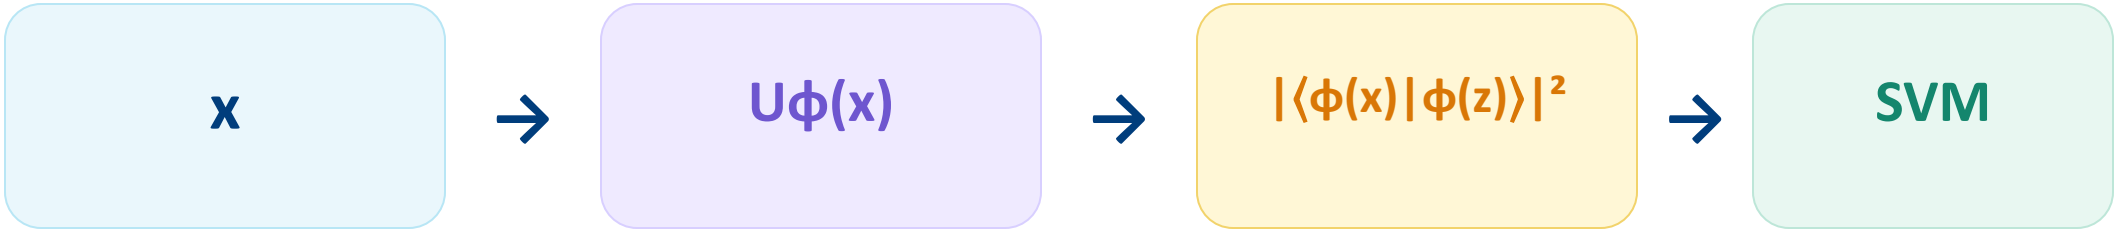
pred_rbf = rbf.predict(X_test_s)
print(classification_report(y_test, pred_rbf, digits=3))
```

Baseline menjawab

- Apakah masalah sudah mudah secara klasik?
- Apakah fitur yang dipilih informatif?
- Berapa biaya dan waktu pelatihan?
- Apakah QML memberi trade-off yang berarti?

Bandingkan pada split yang sama.

Apa yang dilakukan quantum kernel?



Data → keadaan kuantum → kemiripan → keputusan klasik

Potensi muncul bila feature map mengekspresikan struktur yang relevan dan sulit ditangkap kernel klasik.

Latih QSVC dengan fidelity quantum kernel

```
from qiskit.circuit.library import zz_feature_map
from qiskit_machine_learning.kernels import FidelityQuantumKernel
from qiskit_machine_learning.algorithms import QSVC

feature_map = zz_feature_map(
    feature_dimension=X_train_s.shape[1],
    reps=2, entanglement="linear"
)

qkernel = FidelityQuantumKernel(feature_map=feature_map)
qsvc = QSVC(quantum_kernel=qkernel)
qsvc.fit(X_train_s, y_train)

pred_q = qsvc.predict(X_test_s)
```

Jaga eksperimen

- 2–6 fitur dahulu
- Puluhan hingga ratusan sampel
- Seed dan split sama
- Catat waktu runtime
- Bandingkan RBF-SVM
- Jangan klaim advantage dari satu run

Mulai dari simulator sebelum hardware.

Evaluasi pada test set yang sama

1 • Kualitas

Macro-F1, balanced accuracy, recall attack, confusion matrix.

2 • Efisiensi

Waktu training, waktu prediksi, jumlah evaluasi kernel, dan penggunaan memori.

3 • Stabilitas

Ulangi beberapa seed. Laporkan rata-rata dan simpangan, bukan skor terbaik saja.

Laporan minimum

dataset + versi • fitur • split • seed • preprocessing • model • metrik • runtime • keterbatasan

Ablation study: uji sumber performa

Versi	Fitur	Pertanyaan	Harapan
A	4 fitur flow klasik	Baseline minimal	Masuk akal
B	A + qber	Apakah QBER menambah sinyal?	Ukur
C	B + fidelity + qber_delta	Apakah fitur redundan membantu?	Waspada
D	C + is_anomalous_qkd	Apakah skor melonjak karena shortcut?	Audit
E	v4 + skor risiko	Apakah skor risiko berasal dari label?	Audit ketat

Jika D/E melonjak drastis, jangan buru-buru menyebut model lebih pintar.

BATAS KLAIM

Apa yang boleh dan tidak boleh disimpulkan

Boleh

- Membandingkan QSVC dan SVM pada split yang sama.
- Menyebut hasil sebagai eksperimen pada subset tertentu.
- Mendiskusikan runtime, stabilitas, dan keterbatasan.

Belum boleh

- Mengklaim quantum advantage dari satu dataset kecil.
- Menganggap quantum-inspired sama dengan data hardware QKD.
- Mengabaikan leakage karena skornya menarik.

Ringkasan dan tantangan mandiri

Empat hal yang dibawa pulang

- Baca artefak, bukan hanya deskripsi halaman.
- Mulai dari v3 dan subset kecil untuk QML.
- Audit imbalance, redundansi, dan target leakage.
- Bandingkan QSVC dengan baseline klasik secara adil.

Tantangan

Buat dua eksperimen:

A. tanpa anomaly flag
B. dengan anomaly flag

Bandingkan macro-F1, recall attack, runtime, dan jelaskan apakah terjadi shortcut learning.

data.mendeley.com/datasets/68rc9crgkj/1